Tema 2

VARIABLES ALEATORIAS

En la mayoría de los experimentos aleatorios no existe una única variable que podamos medir sino una gran cantidad de ellas. Pensemos por ejemplo en el experimento de lanzar un dado. En este caso la única variable que suele despertar interés es el "número que sale", es decir, el número de puntos que podemos contar en la cara superior del dado una vez que éste se detiene. Sin embargo podríamos estar interesados en muchas otras variables tales como el ruido que hace el dado (medido, por ejemplo, en decibelios), el número de veces que rebota contra la mesa antes de detenerse o el tiempo que tarda en hacerlo. Todas estas variables son impredecibles a priori y por tanto aleatorias.

2.1. Distribuciones discretas y continuas

En general, una **variable aleatoria** se define como una función que asigna a cada posible resultado de un experimento un número real.

$$X : \Omega \to \mathbb{R}$$

Podremos considerar entonces sucesos del tipo:

$$(X \in A) \equiv \{w \in \Omega : X(w) \in A\} \subseteq \Omega$$

El que no podamos conocer a priori el valor que va a tomar una variable no significa que no podamos llegar a saber muchas cosas importantes sobre ella. La **distribución** de una variable aleatoria determina qué valores puede tomar y con qué probabilidad.

El conjunto de valores que puede tomar es lo que se conoce como su **soporte**. Denotaremos el soporte de la variable X por S_X.

En función de cómo sea el soporte se establece la siguiente clasificación:

- Distribuciones **discretas**: Son aquellas que tienen soporte finito o numerable (ej: número que sale en el dado).
- Distribuciones **continuas**: Tienen soporte no numerable y la probabilidad de un sólo punto es siempre cero (ej: tiempo que tarda en pararse el dado).
- Distribuciones mixtas: Tienen soporte no numerable pero también existen puntos que acumulan probabilidad (ej: tiempo de espera en una cola).

2.1.1. Distribuciones discretas

Existen dos funciones que caracterizan completamente la distribución de una variable aleatoria discreta; son la función de probabilidad y la función de distribución.

- **Función de probabilidad (o función de masa)**.

  Esta función asigna a cada punto del soporte su probabilidad y toma el valor cero en cualquier punto que no pertenezca al soporte. Tenemos por tanto una función $p : \mathbb{R} \to [0, 1]$ tal que $p(x) = P(X = x)$.

Tenemos además que $p(x) > 0 \Leftrightarrow x \in S_X$, lo que implica, teniendo en cuenta las propiedades de la probabilidad estudiadadas en el capítulo 1, que

$$\sum_{x \in S_X} p(x) = 1$$

.

- **Función de distribución**.

  Es una función $F : \mathbb{R} \to [0, 1]$ definida como $F(t) = P(X \leq t)$. En el caso de distribuciones discretas será:

$$F(t) = \sum_{\substack{x \in S_X \\ x \leq t}} p(x)$$

  y tendrá un aspecto escalonado.

  Toda función de distribución F debe verificar las siguientes propiedades:

  a) $\lim_{t \to -\infty} F(t) = 0$.
  b) $\lim_{t \to +\infty} F(t) = 1$.
  c) F es monótona no decreciente.
  d) F es contínua por la derecha.

<u>*Observación*</u> 2.1. Notese que:

- $P(a < X \leq b) = F(b) - F(a)$.
- $P(a \leq X \leq b) = F(b) - F(a^-)$ donde $F(a^-) \equiv \lim_{t \to a^-} F(t)$.
- $p(a) = F(a) - F(a^-)$.

Esta última expresión nos permite obtener la función de probabilidad a partir de la de distribución.

2.1.2. Distribuciones continuas

Al igual que ocurre en el caso discreto, la distribución de una variable continua queda completamente caracterizada por su función de distribución. Sin embargo ahora la función de probabilidad pierde su sentido pues recordemos que la probabilidad de que una variable continua tome un valor concreto es siempre cero. Lo que necesitamos es una función que nos permita determinar la probabilidad de cualquier intervalo.

- **Función de densidad**. Es una función no negativa $f : \mathbb{R} \to \mathbb{R}$ que toma valores positivos sólo en el soporte de la variable ($f(x) > 0 \Leftrightarrow x \in S_X$), y que verifica:

$$P(a < X < b) = \int_a^b f(x)dx$$

  Análogamente a lo que ocurría con la función de probabilidad, en este caso se tiene:

$$\int_{S_X} f(x)dx = 1$$

- **Función de distribución**.

  La función de distribución se define igual que en el caso discreto ($F : \mathbb{R} \to [0, 1]$ donde $F(t) = P(X \leq t)$) pero ahora se obtendrá como:

$$F(t) = \int_{-\infty}^t f(x)dx$$

  y será siempre continua.

Observación 2.2. Podemos obtener la función de densidad a partir de la de distribución mediante la expresión:

$$f(x) = F'(x)$$

2.2. Principales distribuciones discretas

- Distribución de **Bernoulli**. Se corresponde con una variable aleatoria que sólo puede tomar dos valores: 1 (éxito) ó 0 (fracaso). Depende de un solo parámetro p que determina la probabilidad de éxito y que debe verificar $0 < p < 1$. Se denota como $X \sim \mathcal{B}(p)$.

  - Soporte: $S_X = \{0, 1\}$.
  - Función de probabilidad: $p(1) = p$ y $p(0) = q$.

  donde $q \equiv 1 - p$.

- Distribución **binomial**. Representa el número de éxitos en n pruebas de Bernoulli de parámetro p independientes. Depende por tanto de dos parámetros n y p, que deben verificar $n \in \mathbb{N}$ y $0 < p < 1$. Se denota como $X \sim B(n, p)$.

  - Soporte: $S_X = \{0, 1, ..., n\}$.
  - Función de probabilidad: $p(x) = \binom{n}{x} p^x q^{n-x}$.

  Observación 2.3.

$$\sum_{x \in S_X} p(x) = \sum_{x=0}^{n} \binom{n}{x} p^x q^{n-x} = (p+q)^n = 1$$

  Observación 2.4. Nótese que si tenemos $X_1, ..., X_n \sim \mathcal{B}(p)$ independientes, entonces será:

$$\sum_{i=0}^{n} X_i \sim B(n, p)$$

  De aquí se deduce también que la distribución $\mathcal{B}(p)$ es un caso particular de la $B(n, p)$ en que $n = 1$.

- Distribución **geométrica**. Dada una sucesión de pruebas de Bernoulli de parámetro p independientes, representa el número de pruebas necesarias hasta conseguir el primer éxito. Depende del parámetro p, que debe verificar $0 < p < 1$. Se denota como $X \sim G(p)$

  - Soporte: $S_X = \{1, 2, ...\}$.
  - Función de probabilidad: $p(x) = pq^{x-1}$ donde $q \equiv 1 - p$.

  Observación 2.5.

$$\sum_{x \in S_X} p(x) = \sum_{x=1}^{\infty} pq^{x-1} = \frac{p}{q} \frac{q}{1-q} = 1$$

  Nota 2.6. Se dice que una variable aleatoria X no tiene memoria si verifica, para todo par $x, h > 0$, que

$$P(X > x + h | X > x) = P(X > h)$$

  La distribución geométrica no tiene memoria ya que

$$P(X > x + h | X > x) = \frac{P(X > x + h)}{P(X > x)} =$$

$$= \frac{\sum_{k=x+h+1}^{\infty} pq^{k-1}}{\sum_{k=x+1}^{\infty} pq^{k-1}} = \frac{p\frac{q^{x+h}}{1-q}}{p\frac{q^x}{1-q}} = q^h = P(X > h)$$

  De hecho se puede comprobar que es la única distribución discreta sin memoria.

  Nota 2.7. En ocasiones se utiliza una definición ligeramente distinta, pues se considera el número de fracasos antes del primer éxito. El tratamiento general es muy parecido pero en este caso se tiene:

  - Soporte: $S_X = \{0, 1, ...\}$.
  - Función de probabilidad: $p(x) = pq^x$ donde $q \equiv 1 - p$.

- Distribución **hipergeométrica**. Dado un conjunto de N elementos, de los cuales N_A son de tipo A y N_B son de tipo B, elegimos n de ellos al azar y sin reemplazamiento. En esta situación el número de elementos extraídos de tipo A sigue una distribución hipergeométrica de parámetros N, N_A y n. Los tres parámetros deben ser números naturales y además $n, N_A \leq N$. Se denota como $H(N, N_A, n)$.

  - Soporte: $S_X = \{x \in \mathbb{Z} : \text{máx}\{0, n-N+N_A\} \leq x \leq \text{mín}\{n, N_A\}\}$.
  - Función de probabilidad: $p(x) = \dfrac{\binom{N_A}{x}\binom{N_B}{n-x}}{\binom{N}{n}}$.

  Observación 2.8. Si la elección de los n elementos se hiciera con reemplazamiento tendríamos una distribución binomial de parámetros n y $p = N_A/N$.

- Distribución **binomial negativa** Dada una sucesión de pruebas de Bernoulli de parámetro p independientes, representa el número de pruebas necesarias hasta conseguir el k-ésimo éxito. Depende de los parámetros k y p, que deben verificar $k \in \mathbb{N}$ y $0 < p < 1$. Se denota como $X \sim BN(k, p)$

  - Soporte: $S_X = \{k, k+1, ...\}$.
  - Función de probabilidad: $p(x) = \binom{x-1}{k-1} p^k q^{x-k}$.

  Observación 2.9. Esta distribución generaliza a la Geométrica; si $k = 1$ se convierte en una $G(p)$.

- Distribución de **Poisson**. Dado un suceso que se repite con una frecuencia media de λ veces por unidad de tiempo, representa el número de ocurrencias en una unidad de tiempo. Depende del parámetro λ que debe verificar $\lambda > 0$. Se denota como $X \sim \mathcal{P}(\lambda)$.

- Soporte: $S_X = \{0, 1, ...\}$.
- Función de probabilidad: $p(x) = \dfrac{e^{-\lambda}\lambda^x}{x!}$.

Observación 2.10. Teniendo en cuenta el desarrollo en serie de la función exponencial, se tiene:

$$\sum_{x \in S_X} p(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} e^{\lambda} = 1$$

Nota 2.11. La distribución de Poisson se obtiene como límite de la distribución binomial en el siguiente sentido:

Consideremos un intervalo temporal de longitud 1 y supongamos que lo hemos dividido en n subintervalos de longitud $1/n$. Sea $p(n)$ la probabilidad de que un suceso dado ocurra en un subintervalo de esta longitud.

Si n es suficientemente grande (y por tanto los subintervalos sufientemente pequeños) podremos despreciar la probabilidad de que el suceso ocurra más de una vez en cada subintervalo. Entonces el número de repeticiones del suceso durante el intervalo $(0, 1)$ tendrá una distribución $B(n, p(n))$.

Supongamos por último que la probabilidad $p(n)$ es proporcional a la longitud del subintervalo considerado y sea λ la correspondiente constante de proporcionalidad, es decir, $p(n) = \lambda/n$.

Si ahora definimos $X \equiv$"número de ocurrencias en el intervalo $(0, 1)$", tendremos que $S_X = \{0, 1, ...\}$ y, por otro lado:

$$P(X = x) = \binom{n}{x} p^x q^{n-x} = \frac{n!}{(n-x)!x!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$$

Consideremos ahora qué pasaría si hicieramos crecer el número de subintervalos hasta el infinito, es decir, si hicieramos $n \to \infty$. Entonces:

$$\begin{aligned} P(X = x) &= \lim_{n\to\infty} \frac{n!}{(n-x)!x!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \frac{\lambda^x}{x!} \lim_{n\to\infty} \frac{n!}{(n-x)!} \frac{1}{(n-\lambda)^x} \left(1 - \frac{\lambda}{n}\right)^n \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \lim_{n\to\infty} \frac{n(n-1)\cdots(n-x+1)}{(n-\lambda)^x} = \frac{\lambda^x}{x!} e^{-\lambda} \end{aligned}$$

ya que el último límite resulta ser 1.

2.3. Principales distribuciones continuas

- Distribución **Uniforme**. Es una distribución con densidad de probabilidad uniforme a lo largo del intervalo (a, b) y cero fuera de él. Depende de los parámetros a y b, que deben verificar $a < b$. Se denota como $X \sim U(a, b)$.

  - Soporte: $S_X = (a, b)$.
  - Función de densidad: $f(x) = \dfrac{1}{b-a}$ en (a, b) (y $f(x) = 0$ en el resto).

  Observación 2.12. Obviamente, f integra 1 en el soporte dado.

  Nota 2.13. El término "uniforme" es muy genérico y se utiliza en distintos contextos. Por ejemplo, existe también la distribución Uniforme Discreta de parámetro $n \in \mathbb{N}$, que puede tomar valores $\{1, 2, ..., n\}$, todos ellos con la misma probabilidad $1/n$.

- Distribución **normal** (o **gausiana**). Es, sin duda, la distribución de probabilidad de mayor aplicación en casi todas las áreas. Se utiliza para modelizar todo tipo de medidas, errores estadísticos,

ruidos y perturbaciones, movimientos de partículas, etc. Depende de dos parámetros: μ (media) y σ (desviación típica). Sobre μ no se impone ninguna restricción pero debe ser $\sigma > 0$. Se denota como $X \sim N(\mu, \sigma)$.

- Soporte: $S_X = \mathbb{R}$.
- Función de densidad: $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$ (Campana de Gauss).

Observación 2.14. No existe una expresión explícita para la primitiva de esta función por lo que sólo se puede integrar mediante técnicas numéricas. Existen tablas que permiten calcular probabilidades y puntos críticos sobre la distribución N(0,1) (normal estándar). Para hacer estos cálculos sobre cualquier otra normal tendremos que tipificar.

Tipificación: Se verifica la siguiente propiedad:

$$X \sim N(\mu, \sigma) \Leftrightarrow \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Teorema Central del Límite: Sea $\{X_i\}_{i \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas con media y varianza finitas. Entonces la distribución de la variable $S_n = \sum_{i=1}^{n} X_i$ se hace normal cuando $n \to \infty$.

Podremos entender mejor este resultado, y expresarlo de forma más rigurosa, a medida que avancemos en el curso. Quedémonos de momento con la idea intuitiva de que "la suma de muchos pequeños efectos aleatorios independientes unos de otros sigue una distribución aproximadamente normal".

- Distribución **exponencial**. Se utiliza frecuentemente para representar tiempos de vida de diversos aparatos, tiempos de llegada de usuarios a un sistema, etc. Depende de un solo parámetro $\lambda > 0$ y se denota como $X \sim exp(\lambda)$.

  - Soporte: $S_X = (0, +\infty)$.
  - Función de densidad: $f(x) = \lambda e^{-\lambda x}$ en $(0, +\infty)$.

  Observación 2.15. Se comprueba trivialmente que: $\int_0^\infty \lambda e^{-\lambda x} dx = 1$.

  Nota 2.16. La exponencial no tiene memoria, pues:

  $$P(X > t) = \int_t^\infty \lambda e^{-\lambda x} dx = e^{-\lambda t}$$

  lo cuál implica que:

  $$P(X > t+h|X > h) = \frac{P(X > t+h)}{P(X > h)} = \frac{e^{-\lambda(t+h)}}{e^{-\lambda h}} = e^{-\lambda t} = P(X > t)$$

  De hecho se puede comprobar que es la única distribución continua sin memoria.

  Nota 2.17. Entre la distribución exponencial y la de Poisson existe una curiosa relación, que vamos a utilizar repetidas veces a lo largo de la asignatura:

  Consideremos un suceso que se repite aleatoriamente en el tiempo. Entonces el número de repeticiones por unidad de tiempo sigue una distribución $\mathcal{P}(\lambda)$ si y sólo si el tiempo que transcurre entre dos repeticiones sigue una distribución $exp(\lambda)$.

  Veamos de momento la implicación directa, la otra podremos demostrarla cuando lleguemos al tema 3. Sea $N(t)$ el número de ocurrencias del suceso durante t unidades de tiempo y supongamos que $N(t) \sim \mathcal{P}(\lambda t)$. Por otra parte, sea T el tiempo transcurrido entre dos ocurrencias. Entonces

  $$P(T > t) = P(N(t) = 0) = e^{-\lambda t} \Rightarrow T \sim exp(\lambda)$$

- Distribución **gamma**. Es un modelo muy versátil que incluye como casos particulares las distribuciones exponencial, Erlang y χ^2. Depende de dos parámetros, p y λ que deben verificar $p, \lambda > 0$. Se denota como $X \sim Gamma(p, \lambda)$.

  - Soporte: $S_X = (0, +\infty)$.
  - Función de densidad: $f(x) = \dfrac{\lambda^p}{\Gamma(p)} x^{p-1} e^{-\lambda x}$ en $(0, +\infty)$

  siendo

  $$\Gamma(p) = \int_0^\infty x^{p-1} e^{-x} dx$$

  la conocida como función Gamma.

  Observación 2.18. Aplicando el cambio $y = \lambda x$ se comprueba fácilmente que $\int_{S_X} f(x)dx = 1$.

  Observación 2.19. Cuando $p = 1$ se tiene que $Gamma(1, \lambda) \equiv exp(\lambda)$.

  Nota 2.20. Se puede comprobar que para $n \in \mathbb{N}$ es $\Gamma(n) = (n-1)!$ La distribución que se obtiene en este caso, con función de densidad

  $$f(x) = \frac{\lambda^p}{(n-1)!} x^{p-1} e^{-\lambda x} \quad \text{en } (0, +\infty)$$

  se conoce como $n - Erlang(\lambda)$.

  Nota 2.21. Se puede ver que si $X_1, ..., X_n$ es una colección de variables independientes con distribución $exp(\lambda)$, entonces la suma de todas ellas sigue una distribución $n - Erlang(\lambda)$.

2.4. Momentos de una variable aleatoria

Los momentos de una variable aleatoria son valores numéricos que se calculan sobre su distribución y que nos dan una idea bastante precisa (aunque no exacta) de cómo es dicha distribución. Los más importantes son la media y la varianza.

2.4.1. La media

La **media** (o **esperanza**) de una variable aleatoria es una medida de posición que proporciona un valor numérico en torno al cuál se sitúan las distintas realizaciones de la variable.

Se define como

$$E[X] = \begin{cases} \sum_{x \in S} xp(x) & \text{en variables discretas} \\ \int_S xf(x)dx & \text{en variables continuas} \end{cases}$$

A menudo la denotaremos con la letra griega μ.

Ejemplo 2.1. Veamos cómo calcular la media de algunas distribuciones conocidas:

- Dada $X \sim \mathcal{B}(p)$,
$$E[X] = 0 \cdot q + 1 \cdot p = p$$
- Dada $X \sim U(a, b)$,
$$E[X] = \int_a^b \frac{x}{b-a} dx = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}$$

Propiedades de la media: Teniendo en cuenta la definición anterior es fácil comprobar que:

- $E[C] = C$ si C es una constante.
- $E[X + Y] = E[X] + E[Y]$.
- $E[CX] = CE[X]$.
- $E[XY] = E[X]E[Y]$ si X e Y son independientes.

La última propiedad se podrá demostrar cuando estudiemos la independencia de variables aleatorias en el Tema 3.

Nota 2.22. En ocasiones nos referiremos a la media como el momento de orden 1 respecto del origen. De forma general, se define el **momento de orden k** como:

$$\alpha_k = E[X^k]$$

2.4.2. La varianza

La **varianza** es una medida de dispersión que refleja la mayor o menor tendencia de la variable a tomar valores alejados de su media.

Se define como

$$V[X] = E[(X-\mu)^2] = \begin{cases} \sum_{x \in S} (x-\mu)^2 p(x) & \text{en variables discretas} \\ \int_S (x-\mu)^2 f(x)dx & \text{en variables continuas} \end{cases}$$

A menudo la denotaremos con la letra griega σ^2.

Observación 2.23. Podemos desarrollar la fórmula anterior como sigue:

$$E[(X-\mu)^2] = E[X^2 - 2X\mu + \mu^2] = E[X^2] - 2\mu E[X] + \mu^2 = E[X^2] - \mu^2$$

Obtenemos de este modo la siguiente fórmula, que facilita notablemente el cálculo y es válida tanto para variables discretas como continuas:

$$\sigma^2 = \alpha_2 - \alpha_1^2$$

Ejemplo 2.2. Veamos cómo calcular la varianza de algunas distribuciones conocidas:

- Dada $X \sim \mathcal{B}(p)$,

$$V[X] = (0-p)^2 \cdot q + (1-p)^2 \cdot p = p^2 q + q^2 p = pq$$

- Dada $X \sim U(a,b)$,

$$E[X^2] = \int_a^b \frac{x^2}{b-a} dx = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3}$$

Ahora

$$V[X] = \alpha_2 - \alpha_1^2 = \frac{a^2 + ab + b^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12}$$

Propiedades de la varianza: Se comprueba fácilmente que:

- $V[C] = 0$ si C es una constante.
- $V[CX] = C^2 V[X]$.
- $V[X + Y] = V[X] + V[Y]$ si X e Y son independientes.

La última propiedad se podrá demostrar cuando estudiemos la independencia de variables aleatorias en el Tema 3.

A menudo, en vez de la varianza se utiliza la **desviación típica** (o **desviación estándar**), que se denota por σ y se define como la raíz cuadrada de la varianza.

Nota 2.24. Una transformación muy utilizada para trabajar con variables aleatorias es la **tipificación**. Tipificar una variable consiste en restarle su media y dividirla por su desviación típica. Es fácil comprobar que una variable tipificada tiene siempre media cero y desviación típica uno.

Finalmente, veamos un resultado que nos ayudará a entender mejor la información que proporcionan la media y la varianza sobre la distribución de la que provienen:

Desigualdad de Tchebychev: *Dada una variable aleatoria X con media μ y varianza σ^2, se tiene para todo $a > 0$ que*

$$P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$$

2.4.3. Funciones de variables aleatorias

Sea X una v.a. y $g : \mathbb{R} \to \mathbb{R}$ una función. Entonces $Y = g(X)$ será otra variable aleatoria y podemos calcular probabilidades sobre ella así:

$$P(Y \in A) = P(X \in g^{-1}(A))$$

siendo $g^{-1}(A) = \{x \in \mathbb{R} : g(x) \in A\}$.

Ejemplo 2.3. Sea $X \sim U(0, 2)$, es decir, $f_X(x) = 1/2$ en el intervalo $(0, 2)$, y sea $Y = X^2$. Entonces:

$$P(Y \leq 2) = P(-\sqrt{2} \leq X \leq \sqrt{2}) = P(0 \leq X \leq \sqrt{2}) = \frac{\sqrt{2}}{2}$$

Ejemplo 2.4. Sea $X \sim exp(2)$, es decir, $f_X(x) = 2e^{-2x}$ si $x > 0$, y sea $Y = \dfrac{X}{X+1}$. Calcula $P(1/3 < Y < 1/2)$.

Tenemos que:

$$\frac{1}{3} < \frac{X}{X+1} < \frac{1}{2} \Leftrightarrow \frac{X+1}{3} < X < \frac{X+1}{2}$$

Nótese que $X > 0$ por ser exponencial. Deben cumplirse entonces dos cosas:

- $(X + 1)/3 < X \Leftrightarrow X + 1 < 3X \Leftrightarrow X > 1/2$
- $X < (X + 1)/2 \Leftrightarrow 2X > X + 1 \Leftrightarrow X < 1$

Llegamos por tanto a que

$$P(1/3 < Y < 1/2) = P(1/2 < X < 1) \approx 0{,}2325$$

A la hora de calcular esperanzas se tiene:

$$E[Y] = E[g(X)] = \begin{cases} \sum_{x \in S} g(x)p(x) & \text{si } X \text{ es discreta} \\ \int_S g(x)f(x)dx & \text{si } X \text{ es continua} \end{cases}$$

Se calcularan de forma análoga los momentos de cualquier orden y la varianza de Y.

2.5. Funciones generatrices

Las funciones generatrices son útiles, entre otras cosas, para obtener momentos de cualquier orden de una distribución dada.

- **Función característica** (Transformada de Fourier). Se define como:

$$\phi_X(\omega) = E[e^{j\omega X}] = \begin{cases} \sum_{x \in S} e^{j\omega x}p(x) & \text{si } X \text{ es discreta} \\ \int_S e^{j\omega x}f(x)dx & \text{si } X \text{ es continua} \end{cases}$$

  siendo j la unidad imaginaria.

  Verifica las siguientes propiedades:

  - Caracteriza completamente la distribución de X. De hecho, se puede obtener la función de densidad a partir de ϕ_X utilizando la antitransformada:

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \phi_X(\omega) e^{-j\omega x} d\omega$$

  - Siempre existe (la suma o integral asociada siempre converge).
  - Si $X_1, ..., X_n$ son variables aleatorias independientes, se verifica:

$$\phi_{X_1 + \cdots + X_n}(\omega) = \prod_{i=1}^{n} \phi_{X_i}(\omega)$$

Resulta muy útil para calcular momentos de cualquier orden ya que se tiene:

$$\left.\frac{d\phi}{d\omega}\right|_{\omega=0} = E[e^{j\omega X}(jX)]|_{\omega=0} = jE[X]$$

y, en general:

$$\left.\frac{d^k\phi}{d\omega^k}\right|_{\omega=0} = E[e^{j\omega X}(jX)^k]|_{\omega=0} = j^kE[X^k]$$

con lo cual:

$$\alpha_k = \frac{1}{j^k}\left.\frac{d^k\phi}{d\omega^k}\right|_{\omega=0}$$

Ejemplo: Consideremos la distribución $B(n,p)$, definida en la sección 2.2. Su función característica será:

$$\phi_X(\omega) = \sum_{x=0}^{n} e^{j\omega x}\left(\begin{array}{c} n \\ x \end{array}\right)p^xq^{n-x} = \sum_{x=0}^{n}\left(\begin{array}{c} n \\ x \end{array}\right)(pe^{j\omega})^xq^{n-x} = (pe^{j\omega}+q)^n$$

Ahora podemos calcular:

$$E[X] = \alpha_1 = \frac{1}{j}\left.\frac{d\phi}{d\omega}\right|_{\omega=0} = \frac{1}{j}n(pe^{j\omega}+q)^{n-1}pe^{j\omega}j|_{\omega=0} = np$$

En cuanto al momento de orden 2:

$$\alpha_2 = \frac{1}{j^2}\left.\frac{d^2\phi}{d\omega^2}\right|_{\omega=0} = \frac{npj}{j^2}\{(n-1)(pe^{j\omega}+q)^{n-2}pe^{j\omega}je^{j\omega}+(pe^{j\omega}+q)^{n-1}e^{j\omega}j\}|_{\omega=0} =$$

$$= \frac{np}{j}\{(n-1)pj + j\} = n(n-1)p^2 + np$$

con lo cuál tenemos que:

$$V[X] = \alpha_2 - \alpha_1^2 = n(n-1)p^2 + np - (np)^2 = np(1-p)$$

- Función generatriz de momentos (Transformada de Laplace). Se define sobre variables aleatorias continuas no negativas, como sigue:

$$M_X(s) = E[e^{-sX}] = \int_0^\infty e^{-sx} f(x)dx$$

Si $X_1, ..., X_n$ son variables aleatorias independientes, se verifica:

$$M_{X_1+\cdots+X_n}(s) = \prod_{i=1}^{n} M_{X_i}(s)$$

Razonando como con la función característica se comprueba fácilmente que:

$$\alpha_k = (-1)^k \left.\frac{d^k M}{ds^k}\right|_{s=0}$$

lo que la hace muy útil para calcular momentos de cualquier orden.

Ejemplo: Consideremos la distribución $Gamma(p, \lambda)$, definida en la sección 2.3. Su función generatriz de momentos es:

$$M_X(s) = \int_0^\infty e^{-sx} \frac{\lambda^p}{\Gamma(p)} x^{p-1} e^{-\lambda x} dx$$

Esto se puede poner como:

$$M_X(s) = \frac{\lambda^p}{(\lambda+s)^p} \int_0^\infty \frac{(\lambda+s)^p}{\Gamma(p)} x^{p-1} e^{-(\lambda+s)x} dx = \left(\frac{\lambda}{\lambda+s}\right)^p$$

ya que lo que hay dentro de la integral es la función de densidad de una $Gamma(p, \lambda + s)$ y, por tanto, debe integrar 1.

Ahora podemos obtener su esperanza como:

$$E[X] = \alpha_1 = (-1)\left.\frac{dM}{ds}\right|_{s=0} = -p\left(\frac{\lambda}{\lambda+s}\right)^{p-1}\left.\frac{-\lambda}{(\lambda+s)^2}\right|_{s=0} = \frac{p}{\lambda}$$

En cuanto a la varianza se tiene:

$$\alpha_2 = \left.\frac{d^2M}{ds^2}\right|_{s=0} = \frac{-p(p+1)}{\lambda}\left(\frac{\lambda}{\lambda+s}\right)^{p}\left.\frac{-\lambda}{(\lambda+s)^2}\right|_{s=0} = \frac{p(p+1)}{\lambda^2}$$

$$V[X] = \frac{p(p+1)}{\lambda^2} - \frac{p^2}{\lambda^2} = \frac{p}{\lambda^2}.$$

Podemos utilizar la función generatriz de momentos para demostrar que la distribución $Gamma(p, \lambda)$ es reproductiva respecto de su parámetro p. En efecto: considérese una colección de variables independientes $X_1, ..., X_n$ con $X_i \sim Gamma(p_i, \lambda)$ y sea $Y = \sum_{i=1}^{n} X_i$. Queremos probar que $Y \sim Gamma\left(\sum_{i=1}^{n} p_i, \lambda\right)$.

Anteriormente, hemos demostrado que la función generatriz de momentos de la distribución $Gamma(p, \lambda)$ es $M(s) = \left(\frac{\lambda}{\lambda+s}\right)^{p}$. Tenemos por tanto que $M_{X_i}(s) = \left(\frac{\lambda}{\lambda+s}\right)^{p_i}$.

Ahora, utilizando las propiedades de la función generatriz de momentos,

$$M_Y(s) = \prod_{i=1}^{n} M_{X_i}(s) = \prod_{i=1}^{n}\left(\frac{\lambda}{\lambda+s}\right)^{p_i} = \left(\frac{\lambda}{\lambda+s}\right)^{\sum_{i=1}^{n} p_i}$$

De aquí se concluye que $Y \sim Gamma\left(\sum_{i=1}^{n} p_i, \lambda\right)$.

A partir de aquí se deduce que la suma de n variables con distribución $exp(\lambda)$ independientes, tiene una distribución $n - Erlang(\lambda)$. En efecto: la distribución exponencial es un caso particular de gamma, ya que $exp(\lambda) \equiv Gamma(p = 1, \lambda)$. Por lo tanto, si $X_1, ..., X_n \sim exp(\lambda)$ independientes, tenemos que

$$X_1 + \cdots + X_n \sim Gamma(n, \lambda) \equiv n - Erlang(\lambda)$$

- Función generatriz de probabilidad (Transformada z). Se define sobre variables aleatorias discretas no negativas, como sigue:

$$G_X(z) = E[z^X] = \sum_{x=0}^{\infty} z^x p(x)$$

Si $X_1, ..., X_n$ son variables aleatorias independientes, se verifica:

$$G_{X_1+\cdots+X_n}(z) = \prod_{i=1}^{n} G_{X_i}(z)$$

Se tiene que:

- $p(k) = \dfrac{1}{k!}\dfrac{d^k G}{dz^k}|_{z=0}$
- $E[X] = G'(1)$
- $V[X] = G''(1) + G'(1) - [G'(1)]^2$

Ejemplo: Consideremos la distribución $P(\lambda)$, definida en la sección 2.2. Su función generatriz de probabilidad será:

$$G_X(z) = \sum_{x=0}^{\infty} z^x \frac{e^{-\lambda}\lambda^x}{x!} = \frac{e^{-\lambda}}{e^{-\lambda z}} \sum_{x=0}^{\infty} \frac{e^{-\lambda z}(\lambda z)^x}{x!} = e^{\lambda(z-1)}$$

ya que lo que hay dentro del sumatorio es la función de probabilidad de una $\mathcal{P}(\lambda z)$ y debe sumar 1.

Ahora podemos calcular la media:

$$E[X] = \left.\frac{dG}{dz}\right|_{z=1} = e^{\lambda(z-1)}\lambda|_{z=1} = \lambda$$

y la varianza:

$$\left.\frac{d^2G}{dz^2}\right|_{z=1} = e^{\lambda(z-1)}\lambda^2|_{z=1} = \lambda^2 \Rightarrow V[X] = \lambda$$