Tema 3

VECTORES ALEATORIOS

En general, cuando se trabaja sobre un determinado experimento aleatorio, existe más de una variable en la que estamos interesados. Es más, a menudo no nos interesa exclusivamente la distribución de probabilidad individual asociada a cada una de las variables sino que resulta especialmente importante el estudio de las posibles relaciones existentes entre ellas. En dichos casos el enfoque más apropiado consiste en agrupar todas las variables en un vector y estudiar el comportamiento aleatorio de dicho vector.

En este capítulo se generaliza buena parte de los conceptos definidos en el capítulo 2 para variables aleatorias unidimensionales, al caso de vectores aleatorios de cualquier dimensión, si bien, buscando una mayor simplicidad, nos centraremos en el caso bidimensional. La generalización a vectores k-dimensionales no presenta grandes dificultades y se puede encontrar en la mayoría de los libros que incluimos en la bibliografía.

Un **vector aleatorio** de dimensión 2 se define como una función que asigna a cada posible resultado de un experimento aleatorio un vector de $\mathbb{R}^2$:

$$\begin{aligned} X: \ & \Omega \to \mathbb{R}^2 \\ & \omega \to (X(\omega), Y(\omega)) \end{aligned}$$

Los sucesos serán ahora de la forma $(X, Y) \in A$ donde $A \subset \mathbb{R}^2$.

3.1. Distribución conjunta y distribuciones marginales

La distribución conjunta de las variables X e Y contiene toda la información sobre el comportamiento aleatorio del vector (X, Y), tanto la referida al comportamiento individual de cada una de las variables como la referida a cualquier posible relación existente entre ellas.

- **Caso discreto**.

  Dadas dos variables aleatorias discretas X e Y, decimos que el vector (X, Y) es un vector aleatorio discreto. Se define la **función de probabilidad conjunta** de X e Y como:

$$\begin{aligned} p_{XY}: \quad & \mathbb{R}^2 \to [0,1] \\ & (x,y) \to p_{XY}(x,y) \ = P(X = x, Y = y) \end{aligned}$$

  Se define el soporte de (X, Y) como el conjunto

$$S_{XY} = \{(x,y) \in \mathbb{R}^2 : p_{XY}(x,y) > 0\}$$

  Análogamente a lo que ocurría en el caso unidimensional debe verificarse:

$$\sum_{(x,y) \in S_{XY}} p_{XY}(x,y) = 1$$

Ejemplo 3.1. Considera un vector bidimensional discreto con función de probabilidad $p_{XY}(0,0) = p_{XY}(1,0) = p_{XY}(1,1) = p_{XY}(2,1) = 1/4$. En este caso es

$$S_{XY} = \{(0,0), (1,0), (1,1), (2,1)\}$$

Lógicamente, al ser X e Y variables discretas, el soporte S_{XY} será finito o numerable. Ahora tenemos que, dado $A \in \mathbb{R}^2$,

$$P((X,Y) \in A) = \sum_{(x,y)\in A\cap S_{XY}} p_{XY}(x,y)$$

Por ejemplo, $P(X+Y<2) = p_{XY}(0,0) + p_{XY}(1,0) = 1/2$.

Si queremos estudiar el comportamiento individual de las variables X e Y debemos obtener sus distribuciones marginales. Se define la **función de probabilidad marginal** de X como:

$$p_X(x) = P(X = x, Y = \text{cualquier valor}) = \sum_{y\in S_{Y|X=x}} p_{XY}(x,y)$$

siendo $S_{Y|X=x} = \{y \in \mathbb{R} : p_{XY}(x,y) > 0\}$ el soporte de Y condicionado por el suceso $X = x$. Análogamente

$$p_Y(y) = \sum_{x\in S_{X|Y=y}} p_{XY}(x,y)$$

Observación 3.1. p_X y p_Y son funciones de probabilidad unidimensionales como las estudiadas en el tema 2. En particular se debe cumplir

$$\sum_{x\in S_X} p_X(x) = \sum_{y\in S_Y} p_Y(y) = 1$$

Ejemplo 3.2. En el ejemplo anterior tenemos que $p_X(0) = 1/4$, $p_X(1) = 1/2$ y $p_X(2) = 1/4$. En cuanto a Y, $p_Y(0) = 1/2$ y $p_Y(1) = 1/2$. Los soportes marginales son por tanto $S_X = \{0, 1, 2\}$ y $S_Y = \{0, 1\}$.

Obsérvese que en este caso $S_X \times S_Y = \{(0,0), (0,1), (1,0), (1,1), (2,0), (2,1)\}$, luego se tiene que $S_{XY} \neq S_X \times S_Y$

- **Caso continuo**.

  Dadas dos variables continuas X e Y, se dice que el vector aleatorio (X, Y) tiene distribución continua (ó que X e Y son conjuntamente continuas) si existe una función $f_{XY} : \mathbb{R}^2 \to \mathbb{R}$ no negativa e integrable tal que:

$$P((X, Y) \in A) = \iint_A f_{XY}(x, y)dxdy$$

  para todo $A \subseteq \mathbb{R}^2$. Dicha función se llama **función de densidad conjunta** de X e Y.

  Observación 3.2. Paradójicamente el que dos variables X e Y sean continuas no implica el que su distribución conjunta lo sea. Considerese por ejemplo el vector (X, X^2) siguiendo X cualquier distribución unidimensional continua.

  Se define el soporte de (X, Y) como el conjunto

$$S_{XY} = \{(x, y) \in \mathbb{R}^2 : f_{XY}(x, y) > 0\}$$

  En este caso S_{XY} será no numerable y debe verificarse:

$$\iint_{S_{XY}} f_{XY}(x, y)dxdy = 1$$

Ejemplo 3.3. Considera una distribución bidimensional continua con $f_{XY}(x,y) = K$ en el soporte $S_{XY} = \{x^2+y^2 \leq 1\}$. Comprueba que para que f_{XY} sea una función de densidad bien definida debe ser $K = 1/\pi$.

Si queremos calcular, por ejemplo, $P(X+Y>1)$, tenemos que

$$P(X+Y>1) = \iint_A f_{XY}(x,y)dxdy$$

siendo A la región formada por los puntos del soporte que verifican la condición $x+y>1$. Puedes comprobar que dicha probabilidad resulta ser $\frac{\pi-2}{4\pi} \approx 0{,}0908$.

En analogía con el caso discreto, se definen las funciones de densidad marginales de X e Y respectivamente como:

$$f_X(x) = \int_{S_{Y|X=x}} f_{XY}(x,y)dy \quad \text{y} \quad f_Y(y) = \int_{S_{X|Y=y}} f_{XY}(x,y)dx$$

Lógicamente debe verificarse:

$$\int_{S_X} f_X(x)dx = \int_{S_Y} f_Y(y)dy = 1$$

Ejemplo 3.4. En el ejemplo anterior, la densidad marginal de X es

$$f_X(x) = \int_{-\sqrt{1-x^2}}^{+\sqrt{1-x^2}} \frac{1}{\pi}dy = \frac{2}{\pi}\sqrt{1-x^2} \quad \text{en } -1<x<1$$

La densidad marginal de Y se obtiene de forma análoga.

Observa que en este caso $S_X \times S_Y = [-1,1]^2$, luego $S_{XY} \neq S_X \times S_Y$.

Nota 3.3. Existe también la posibilidad de definir vectores (X, Y) en que X sea discreta e Y sea continua.

Se define la **función de distribución conjunta** de X e Y como:

$$F_{XY}(t_1, t_2) = P(X \leq t_1, Y \leq t_2) = \begin{cases} \sum_{(x,y)\in A} p(x,y) & \text{c. discreto} \\ \iint_A f(x,y)dxdy & \text{c. continuo} \end{cases}$$

siendo $A = \{(x, y) \in S_{XY} : x \leq t_1, y \leq t_2\}$.

Cualquier función de distribución bidimensional debe cumplir las siguientes propiedades:

a) $\lim_{x\to-\infty} F_{XY}(x, y) = \lim_{y\to-\infty} F_{XY}(x, y) = 0$

b) $\lim_{x,y\to\infty} F_{XY}(x, y) = 1$

c) $F_{XY}(x_1, y_1) \leq F_{XY}(x_2, y_2)$ si $x_1 \leq x_2$ e $y_1 \leq y_2$

d) $\lim_{x\to a^+} F_{XY}(x, b) = F_{XY}(a, b)$
$\lim_{y\to b^+} F_{XY}(a, y) = F_{XY}(a, b)$

Observación 3.4. Las siguientes igualdades permiten calcular probabilidades a partir de la función de distribución:

- $P(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F_{XY}(x_2, y_2) - F_{XY}(x_1, y_2) - F_{XY}(x_2, y_1) + F_{XY}(x_1, y_1)$.
- En el caso discreto: $P_{XY}(x, y) = F_{XY}(x, y) - F_{XY}(x^-, y) - F_{XY}(x, y^-) + F_{XY}(x^-, y^-)$.
- En el caso continuo: $F_{XY}(x, y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f_{XY}(t_1, t_2)dt_1dt_2$, luego se tiene:

$$f_{XY}(x, y) = \frac{\partial^2 F}{\partial y \partial x}(x, y)$$

Las **funciones de distribución marginales** de X e Y se pueden obtener como sigue:

$$F_X(x) = P(X \leq x) = \lim_{y\to\infty} F_{XY}(x, y)$$
$$F_Y(y) = P(Y \leq y) = \lim_{x\to\infty} F_{XY}(x, y)$$

Observación 3.5. Las distribuciones marginales se pueden obtener a partir de la conjunta. Sin embargo la conjunta no se puede obtener a partir de las marginales, salvo cuando las variables son independientes.

3.2. Estudio de la relación entre dos variables aleatorias

Una de las ventajas de estudiar dos variables aleatorias de forma conjunta es la posibilidad de estudiar la posible relación existente entre ellas. Cuando no existe ninguna relación decimos que las variables son independientes. A su vez, si dicha relación existe, la distribución de cada variable se ve influida por el valor que tome la otra variable. Este hecho da lugar a las llamadas distribuciones condicionadas.

A lo largo de esta sección hablaremos también de una de las formas más sencillas de relación entre variables, la relación lineal o correlación.

3.2.1. Independencia de variables aleatorias

Decimos que dos variables aleatorias X e Y son independientes si, dados dos sucesos $(X \in A_1)$ e $(Y \in A_2)$, se tiene que

$$P(X \in A_1, Y \in A_2) = P(X \in A_1)P(Y \in A_2)$$

Se puede demostrar que las siguientes afirmaciones son equivalentes:

a) X e Y son independientes.

b) Si son discretas, $P_{XY}(x,y) = P_X(x)P_Y(y)$

c) Si son continuas, entonces son conjuntamente continuas y $f_{XY}(x,y) = f_X(x)f_Y(y)$

d) $F_{XY}(x,y) = F_X(x)F_Y(y)$

Ejercicio 3.1. Comprueba que si X e Y son independientes entonces

$$S_{XY} = S_X \times S_Y$$

Nota 3.6. Dada una función $\Phi : \mathbb{R}^2 \to \mathbb{R}$, se define:

$$E[\Phi(X,Y)] = \begin{cases} \sum_{(x,y)\in S_{XY}} \Phi(x,y)P_{XY}(x,y) & \text{c. discreto} \\ \iint_{S_{XY}} \Phi(x,y)f_{XY}(x,y)dxdy & \text{c. continuo} \end{cases}$$

Ejercicio 3.2. Comprueba que si X e Y son independientes entonces

$$E[XY] = E[X]E[Y] \tag{3.1}$$

3.2.2. Correlación

Entre las muchas formas posibles de relación entre variables aleatorias, la más fácil de estudiar y de medir es la relación lineal o **correlación**. A continuación veremos dos formas de medir la relación lineal existente entre dos variables.

Se define el momento de órdenes k y l de las variables X e Y como

$$\alpha_{kl} = E[X^k Y^l] = \begin{cases} \sum_{(x,y)\in S_{XY}} x^k y^l P_{XY}(x,y) & \text{c. discreto} \\ \iint_{S_{XY}} x^k y^l f_{XY}(x,y)dxdy & \text{c. continuo} \end{cases}$$

A partir de estos momentos podemos definir una primera medida de correlación. Calculando el momento de órdenes 1 y 1 sobre las variables centradas (centrar una variable es restarle su media) obtenemos la **covarianza**:

$$\sigma_{XY} \equiv Cov(X,Y) = E[(X-\mu_X)(Y-\mu_Y)]$$

Se dice que dos variables X e Y son **incorreladas** cuando $\sigma_{XY} = 0$.

Observación 3.7. Operando sobre esta definición llegamos a otra expresión que en algunos casos resulta ser muy útil:

$$\sigma_{XY} = E[XY] - E[X][Y] \tag{3.2}$$

Observación 3.8. Aplicando 3.1 sobre 3.2 tenemos que:

$$\text{Independencia} \Rightarrow \text{Incorrelación} \tag{3.3}$$

Sin embargo la implicación contraria no se da ya que puede haber entre las variables otros tipos de relación no lineales que la covarianza no detecta. Considérese por ejemplo un vector discreto con soporte $S_{XY} = \{(-1,0),(0,-1),(1,0)\}$ y probabilidad 1/3 en cada punto.

La covarianza presenta ciertos problemas ya que depende de cosas que no tienen que ver con la correlación que quiere medir, como es la variabilidad individual de cada una de las variables o las unidades de medida empleadas. Una mejora definitiva se obtiene tipificando las variables (tipificar una variable es restarle su media y dividirla por su desviación típica)lo que da lugar al llamado **coeficiente de correlación de Pearson**:

$$\rho_{XY} = E\left[\left(\frac{X-\mu_X}{\sigma_X}\right)\left(\frac{Y-\mu_Y}{\sigma_Y}\right)\right] = \frac{\sigma_{XY}}{\sigma_X\sigma_Y}$$

Dos propiedades importantes del coeficiente de correlación son:

- Toma valores siempre entre -1 y 1.

- Alcanza dichos valores cuando existe una relación lineal entre las variables, es decir, cuando existen dos coeficientes $a \neq 0$ y b tales que $Y = aX + b$.

En efecto: se tiene que

$$E\left[\left(\frac{X-\mu_X}{\sigma_X} \pm \frac{Y-\mu_Y}{\sigma_Y}\right)^2\right] =$$

$$E\left[\left(\frac{X-\mu_X}{\sigma_X}\right)^2\right] + E\left[\left(\frac{Y-\mu_Y}{\sigma_Y}\right)^2\right] \pm 2E\left[\left(\frac{X-\mu_X}{\sigma_X}\right)\left(\frac{Y-\mu_Y}{\sigma_Y}\right)\right]$$

Las dos primeras esperanzas son los momentos de orden 2 de dos variables tipificadas, con lo cuál valen 1 (ya que $\sigma^2 = \alpha_2 - \mu^2$), y la tercera es ρ_{XY}. Sabemos además que todo esto debe ser no negativo por ser la esperanza de un cuadrado, luego se tiene que $2 \pm 2\rho_{XY} \geq 0$. De aquí se deduce que $-1 \leq \rho_{XY} \leq 1$.

Sea ahora $Y = aX + b$ y vamos a calcular ρ_{XY}. Tenemos que $E[Y] = aE[X] + b$ y $V[Y] = a^2V[X]$. Por otro lado

$$E[XY] = E[X(aX+b)] = E[aX^2 + bX] = aE[X^2] + bE[X]$$

luego

$$Cov(X,Y) = E[XY] - E[X]E[Y] = aE[X^2] + bE[X] - E[X](aE[X] + b)$$

$$= a(E[X^2] - E[X]^2)$$

es decir, $Cov(X,Y) = aV[X]$. Ahora:

$$\rho_{XY} = \frac{Cov(X,Y)}{\sqrt{V[X]V[Y]}} = \frac{aV[X]}{\sqrt{V[X]a^2V[X]}} = \frac{a}{|a|}$$

Por tanto $\rho_{XY} = 1$ si $a > 0$ y $\rho_{XY} = -1$ si $a < 0$.

3.2.3. Distribuciones condicionadas

- **Caso discreto**.

  Dado un vector aleatorio discreto (X, Y) y un punto $y \in \mathbb{R}$ con $P(Y = y) > 0$, se define la función de probabilidad de X condicionada por el suceso $Y = y$ como:

$$\begin{aligned} p_{X|Y}(\cdot|y): \ & \mathbb{R} \to [0,1] \\ & x \to p_{X|Y}(x|y) \ = P(X = x|Y = y) \end{aligned}$$

  Observación 3.9. Tenemos entonces que:

$$p_{X|Y}(x|y) = \frac{P(X = x, Y = y)}{P(Y = y)} = \frac{p_{XY}(x, y)}{p_Y(y)} \tag{3.4}$$

  En cuanto al soporte, será $S_{X|Y=y} = \{x \in \mathbb{R} : p_{X|Y}(x|y) > 0\}$ o, equivalentemente,

$$S_{X|Y=y} = \{x \in \mathbb{R} : p_{XY}(x, y) > 0\}$$

  Observación 3.10. De 3.4 se tiene que

$$p_{XY}(x, y) = p_Y(y)p_{X|Y}(x|y) = p_X(x)p_{Y|X}(y|x)$$

  luego la distribución conjunta se puede obtener a partir de las distribuciones marginales y condicionadas.

  En cuanto a la función de distribución condicionada tenemos:

$$F_{X|Y}(x|y) = P(X \leq x|Y = y) = \frac{P(X \leq x, Y = y)}{P(Y = y)}$$

  Teorema de la Probabilidad Total: Dadas dos variables aleatorias X e Y, la primera de ellas discreta, y una región $A \subset \mathbb{R}$ se tiene:

$$P(Y \in A) = \sum_{x \in S_X} p_X(x) P(Y \in A|X = x)$$

- **Caso continuo**.

  La función de distribución se define en este caso como:

$$F_{X|Y}(x|y) = \lim_{h\to 0} P(X \leq x | y < Y \leq y+h) = \lim_{h\to 0} \frac{P(X \leq x, y < Y \leq y+h)}{P(y < Y \leq y+h)}$$

$$= \lim_{h\to 0} \frac{\int_{-\infty}^{x}\int_{y}^{y+h} f_{XY}(t_1,t_2)dt_2dt_1}{\int_{y}^{y+h} f_Y(t)dt} = \lim_{h\to 0} \frac{\int_{-\infty}^{x} hf_{XY}(t_1,c_1)dt_1}{hf_Y(c_2)}$$

  siendo $c_1, c_2 \in (y, y+h)$ (hemos utilizado en la última igualdad el Teorema del Valor Medio para integrales).

  Ahora, cancelando h en numerador y denominador y observando que en el límite, cuando $h \to 0$, debe ocurrir $c_1 = c_2 = y$, concluimos que:

$$F_{X|Y}(x|y) = \frac{\int_{-\infty}^{x} f_{XY}(t,y)dt}{f_Y(y)}$$

  Para obtener la función de densidad tendremos que derivar la expresión anterior:

$$f_{X|Y}(x|y) = \frac{f_{XY}(x,y)}{f_Y(y)}$$

  <u>*Observación*</u> 3.11. De aquí se deduce también que:

$$f_{XY}(x,y) = f_Y(y)f_{X|Y}(x|y) = f_X(x)f_{Y|X}(y|x)$$

  <u>Teorema de la Probabilidad Total</u>: Dadas dos variables aleatorias X e Y, la primera de ellas continua, y una región $A \subset \mathbb{R}$ se tiene:

$$P(Y \in A) = \int_{S_X} P(Y \in A | X = x) f_X(x)dx$$

Observación: Si X e Y son independientes, entonces:

a) $P_{X|Y}(x|y) = P_X(x)$

b) $f_{X|Y}(x|y) = f_X(x)$

c) $F_{X|Y}(x|y) = F_X(x)$

Ejercicio 3.3. Sea $X \sim exp(\lambda = 1)$ e $Y \sim exp(\lambda = X)$. Calcular $f_{XY}(x, y)$, $f_Y(y)$ y $f_{X|Y}(x|2)$.

Esperanza condicionada.

Se define la esperanza de X condicionada por $Y = y$ como:

$$E[X|Y = y] = \begin{cases} \sum_{x \in S_{X|Y=y}} x p_{X|Y}(x|y) & \text{(c. discreto)} \\ \int_{S_{X|Y=y}} x f_{X|Y}(x|y)dx & \text{(c. continuo)} \end{cases}$$

Nota 3.12. Existe una variante del Teorema de la Probabilidad Total que resulta útil a la hora de calcular esperanzas:

- Si Y es una v.a. discreta:

$$E[X] = \sum_{y \in S_Y} E[X|Y = y] p_Y(y)$$

- Si Y es una v.a. continua:

$$E[X] = \int_{S_Y} E[X|Y = y] f_Y(y)dy$$

Lo demostraremos suponiendo que ambas variables son discretas; la demostración en el resto de casos es análoga. Se tiene que:

$$\sum_{y \in S_Y} E[X|Y = y] p_Y(y) = \sum_{y \in S_Y} \sum_{x \in S_{X|Y=y}} x p_{X|Y}(x|y) p_Y(y) =$$

$$= \sum_{y \in S_Y} \sum_{x \in S_{X|Y=y}} x p_{XY}(x,y) = \sum_{x \in S_X} \sum_{y \in S_{Y|X=x}} x p_{XY}(x,y) =$$

$$= \sum_{x \in S_X} x p_X(x) = E[X]$$

Nota 3.13. Todo lo visto hasta ahora en este capítulo se generaliza de manera natural al caso de vectores de dimensión mayor que 2. Puede encontrarse un tratamiento detallado en el libro de Alberto León-García (ver bibliografía de la asignatura).

3.3. Algunos ejemplos de distribuciones multidimensionales

- Distribución **Multinomial**: Supongamos que repetimos n veces, de forma independiente, un experimento aleatorio que puede dar k resultados diferentes con probabilidades $p_1, p_2, ..., p_k$ respectivamente. Sea X_i el número de veces que sale el resultado i.

  Entonces el vector $(X_1, ..., X_k)$ sigue una distribución multinomial de parámetros $n \in \mathbb{N}$ y $p_1, ..., p_k \in [0,1]$, siendo $p_1 + \cdots + p_k = 1$. Se denota como $(X_1, ..., X_k) \sim M(n; p_1, ..., p_k)$.

  - Soporte: $S = \{(x_1, ..., x_k) \in \{0, ..., n\}^k : x_1 + \cdots + x_k = n\}$
  - Función de probabilidad:

$$p(x_1, ..., x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k} \text{ en } S$$

- Distribución **Normal Multivariante**: Un vector $X := (X_1, ..., X_k)$ sigue una distribución normal multivariante con vector de medias

$\vec{\mu} = (\mu_1, ..., \mu_k)$ (μ_i es la media de X_i), y matriz de covarianzas

$$\sum = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1k} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2k} \\ \vdots & \vdots & & \vdots \\ \sigma_{k1} & \sigma_{k2} & \cdots & \sigma_k^2 \end{pmatrix}$$

(σ_i^2 es la varianza de X_i, y σ_{ij} la covarianza entre X_i y X_j), si su función de densidad conjunta en $\mathbb{R}^k$ es

$$f(\vec{x}) = (2\pi)^{-k/2}|\Sigma|^{-1/2} \exp\{-1/2(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\}$$

siendo $\vec{x} = (x_1, ..., x_k)$. Obsérvese que el soporte es $S = \mathbb{R}^k$, y que la matriz $\sum$ siempre será simétrica y definida positiva.

Se puede demostrar que si $X_1, ...X_k$ son variables normales independientes, entonces el vector $X := (X_1, ..., X_k)$ sigue una distribución normal multivariante. Recíprocamente, si $X := (X_1, ..., X_k)$ sigue una distribución normal multivariante, entonces las variables X_i son normales, aunque no necesariamente independientes. Sin embargo, si hay alguna relación entre ellas, ésta tiene que ser lineal, como se demuestra en la siguiente observación.

Observación 3.14. Nótese que si $X_1, ...X_k$ son variables conjuntamente normales (es decir, si $(X_1, ..., X_k) \sim N(\vec{\mu}, \Sigma)$) entonces:

$$\text{Independencia} \Leftrightarrow \text{Incorrelación}$$

La implicación directa ya se vio en 3.3. En cuanto a la implicación inversa, téngase en cuanta que si las variables son incorreladas entonces:

$$\sum = \begin{pmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & \sigma_k^2 \end{pmatrix}$$

Esto nos lleva a:

$$f_{X_1,...,X_k}(x_1,...,x_k) = (2\pi)^{-k/2} \left(\prod_{i=1}^{k} \sigma_i^2 \right)^{-1/2} \exp\left\{ \frac{-1}{2} \sum_{i=1}^{k} \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2 \right\}$$

$$= \prod_{i=1}^{k} (2\pi\sigma_i^2)^{-1/2} \exp\left\{ \frac{-1}{2} \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2 \right\} = \prod_{i=1}^{k} f_{X_i}(x_i)$$

donde $X_i \sim N(\mu_i, \sigma_i)$ para cada $i = 1, ..., k$.

Esto demuestra por una lado que las variables $X_1, ...X_k$ son independientes y por otro que la distribución marginal de cada X_i es $N(\mu_i, \sigma_i)$.

Ejercicio 3.4. Calcula la función de densidad de un vector con distribución normal bivariante de parámetros

$$\vec{\mu} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \text{y} \quad \Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$$

3.3.1. Transformaciones de vectores aleatorios

Sea $(X_1, ..., X_k)$ un vector aleatorio k-dimensional y $g : \mathbb{R}^k \to \mathbb{R}^l$. Si definimos la variable aleatoria $Z = g(X_1, ..., X_k)$ será, para todo suceso $A \subset \mathbb{R}^l$:

$$P(Z \in A) = P((X_1, ..., X_k) \in B)$$

siendo $B = \{(x_1, ..., x_k) \in \mathbb{R}^k : g(x_1, ..., x_k) \in A\}$.

Ejemplo 3.5. Sea (X, Y) un vector aleatorio con densidad conjunta $f_{XY}(x, y) = 2e^{-x}e^{-y}$ si $0 \leq y < x$. Entonces

$$P(X + Y < 1) = P((X, Y) \in B) = \iint_B f_{XY}(x, y)dxdy$$

siendo $B = \{(x, y) \in \mathbb{R}^2 : x + y < 1\}$. Entonces

$$P(X + Y < 1) = \iint_{B \cap S_{XY}} 2e^{-x}e^{-y}dxdy = \int_0^{1/2} \int_y^{1-y} 2e^{-x}e^{-y}dxdy$$

$$= \int_0^{1/2} 2e^{-y}[-e^{-x}]_y^{1-y}dy = \int_0^{1/2} 2e^{-y}(e^{-y} - e^{-1+y})dy$$

$$= \int_0^{1/2} 2e^{-2y}dy - \int_0^{1/2} 2e^{-1}dy = 1 - 2e^{-1} \approx 0{,}6321$$

Observación: Sean X e Y dos variables aleatorias conjuntamente continuas y sea $Z = X + Y$. Entonces:

$$F_Z(z) = P(Z \leq z) = P(X + Y \leq z) = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{z-x} f_{XY}(x, y)dy \right) dx$$

Por lo tanto la función de densidad será:

$$f_Z(z) = F'_Z(z) = \int_{-\infty}^{\infty} f_{XY}(x, z - x)dx$$

Entonces, si X e Y son independientes, la densidad de $X+Y$ se obtiene como convolución de f_X y f_Y:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x)dx = (f_X * f_Y)(z)$$

Ejercicio 3.5. Sean $X_1, ..., X_k$ variables independientes idénticamente distribuidas según una $exp(\lambda)$. Demuestra por inducción que la distribución de $X_1 + \cdots + X_k$ es k-Erlang de parámetro λ.

En algunos casos, a la hora de calcular $P(g(X,Y) \in A)$ puede ser útil aplicar el TPT, como muestra el siguiente ejemplo:

Ejemplo 3.6. Dadas $X, Y \sim exp(\lambda)$ independientes, queremos calcular la función de distribución de $Z = Y/X$. Para ello hacemos

$$F_Z(t) = P(Y/X \leq t) = P(Y \leq tX) = \int_{S_X} P(Y \leq tX | X = x) f_X(x) dx$$

donde hemos aplicado el TPT. Entonces

$$F_Z(t) = \int_0^\infty P(Y \leq tx) \lambda e^{-\lambda x} dx = \int_0^\infty (1 - e^{-\lambda t x}) \lambda e^{-\lambda x} dx = 1 - \int_0^\infty \lambda e^{-\lambda(t+1)x} dx$$

$$= 1 - \frac{1}{t+1} = \frac{t}{t+1} \quad \text{en} \quad t > 0$$

Por último, dado un vector aleatorio continuo $X = (X_1, ..., X_k)$ y una función $g : \mathbb{R}^k \to \mathbb{R}^k$, existe la posibilidad de obtener la densidad de $g(X_1, ..., X_k)$ haciendo un cambio de variable. Para ello debe existir una función diferenciable h tal que para todo $(x_1, ..., x_k) \in \mathbb{R}^k$:

$$(z_1, .., z_k) = g(x_1, .., x_k) \Leftrightarrow (x_1, .., x_k) = h(z_1, .., z_k)$$

Entonces, si se define el vector aleatorio $Z = (Z_1, ..., Z_k) = g(X)$, su soporte será $S_Z = g(S_X)$ y su función de densidad:

$$f_{Z_1 \cdots Z_k}(z_1, ..., z_k) = f_{X_1 \cdots X_k}(h_1(z), ..., h_k(z)) |J_h|$$

Los dos siguientes ejemplos ilustran cómo se puede llevar a cabo el procedimiento descrito:

Ejemplo 3.7. Sea (X, Y) un vector aleatorio con distribucion uniforme en la región $\mathcal{C} = \{x^2 + y^2 < 1\}$, es decir, $f_{XY}(x, y) = 1/\pi$ en $\mathcal{C}$. Consideremos el cambio a polares:

$$R = g_1(X, Y) = +\sqrt{X^2 + Y^2}$$

$$\Theta = g_2(X, Y) = arctg(Y/X)$$

Como sabemos, si $(r, \theta) = g(x, y)$ entonces:

$$x = h_1(r, \theta) = rcos\theta$$

$$y = h_2(r, \theta) = rsen\theta$$

Se tiene además que $|J_h| = r$.

Entonces (R, Θ) es un vector aleatorio continuo con función de densidad

$$f_{R\Theta}(r, \theta) = r/\pi \text{ en } [0, 1] \times [0, 2\pi]$$

Ejemplo 3.8. Sea (X_1, X_2) un vector aleatorio con distribucion uniforme en $S_{X_1X_2} = [0, 1] \times [0, 1]$. Queremos conocer la distribución de $X_1 + X_2$ para lo cuál hacemos el cambio:

$$Z_1 = g_1(X_1, X_2) = X_1 + X_2$$

$$Z_2 = g_2(X_1, X_2) = X_2$$

Obsérvese que si $(z_1, z_2) = g(x_1, x_2)$, entonces

$$x_1 = h_1(z_1, z_2) = z_1 - z_2$$

$$x_2 = h_2(z_1, z_2) = z_2$$

con lo cuál $|J_h| = 1$.

Entonces (Z_1, Z_2) es un vector aleatorio con función de densidad

$$f_{Z_1Z_2}(z_1, z_2) = f_{X_1X_2}(z_1 - z_2, z_2) = 1$$

si $(z_1 - z_2, z_2) \in [0, 1] \times [0, 1]$. Esto quiere decir que (Z_1, Z_2) tiene distribución uniforme en el soporte $S_{Z_1Z_2} = \{(z_1, z_2) : 0 < z_2 < 1, z_2 < z_1 < z_2 + 1\}$. Por último calculamos la marginal de Z_1 y sale:

$$f_{Z_1}(z_1) = \begin{cases} z_1 & \text{si } 0 < z_1 < 1 \\ 2 - z_1 & \text{si } 1 < z_1 < 2 \end{cases}$$